

Análise de Modelos LLM para RAG e Estratégia de Pricing

SaaS Chatbot — Junho 2026

1. Contexto e premissas

- **Caso de uso:** RAG (Retrieval-Augmented Generation) para chatbot SaaS — respostas ancoradas em chunks recuperados de uma base de conhecimento.
 - **Modelo de cobrança escolhido:** Pay-as-you-go pré-pago, cobrança por mensagem/crédito.
 - **Volume estimado:** 1M+ mensagens/mês.
 - **Restrições:** custo de modelo baixo, latência decente, capacidade suficiente para respostas corretas.
-

2. Estratégia de roteamento: 3 camadas

Em vez de escolher um único modelo, a recomendação é um **router por complexidade**, escalando a requisição entre 3 camadas conforme a dificuldade da pergunta e a confiança do retrieval.

Por que 3 camadas e não 2

Com apenas "forte vs fraco" existe uma zona cinzenta mal atendida: ou se manda tudo barato demais (perde qualidade nos casos difíceis) ou se escala cedo demais pro caro (perde economia). A camada intermediária absorve exatamente essa zona cinzenta.

Critérios de escalonamento (sinais para subir de camada)

- 1. **Score de similaridade do retrieval** — se os top-k chunks têm score baixo, a cobertura da base é fraca → escala.
- 2. **Complexidade da pergunta** — heurística simples: múltiplas perguntas em uma, conectores como "e", "mas", "compare".
- 3. **Self-check barato** — pedir para o modelo da Camada 1 incluir um campo `confidence` na resposta (custo marginal de tokens) e escalar se vier baixo.
- 4. **Validação pós-resposta** — checar se a resposta de fato usa/cita o contexto fornecido (regex simples ou outro modelo barato avaliando).

Distribuição de tráfego assumida (referência para os cálculos deste documento)

Camada	% do tráfego
 Barata	85%
 Média	12%
 Forte	3%

3. Modelos por camada — cruzamento com Artificial Analysis Intelligence Index

Dados de preço via OpenRouter (passthrough, sem markup por token — apenas 5,5% na compra de créditos). Dados de qualidade via Artificial Analysis Intelligence Index v4.1 (snapshot jun/2026).

Camada	Modelo	AA Intelligence Index	Input \$/M tokens	Output \$/M tokens	Contexto
 Barata	GLM-4.7-flash	~30–35*	\$0.07	\$0.40	200K

Camada	Modelo	AA Intelligence Index	Input \$/M tokens	Output \$/M tokens	Contexto
 Barata	Qwen3.5-flash	~32–36*	\$0.10	\$0.40	1M
 Barata	DeepSeek V3.2	38	\$0.20	\$0.40	163K
 Média	Gemini 2.5 Flash	~42	\$0.30	\$2.50	1M
 Média	MiniMax M3	44	\$0.30	\$1.20	1M
 Média	DeepSeek V4 Pro	44	~\$0.50	~\$2.00	160K+
 Média	Claude Haiku 4.5	~48–50*	\$1.00	\$5.00	200K
 Forte	GLM-5.2 (max)	51	\$0.80+	\$2.56+	1M
 Forte	Claude Sonnet 4.6	~54–55*	\$3.00	\$15.00	1M
 Forte	Gemini 3.1 Pro	57.2	\$2.00	\$12.00	1M
 Forte	Claude Opus 4.8	61.4	\$5.00	\$25.00	1M

* Estimativa por posição relativa na escala — não há valor exato publicado para esses modelos na snapshot consultada.

Ressalva importante sobre o índice

O AA Intelligence Index mede capacidade geral (raciocínio, coding, agentic), **não especificamente fidelidade de resposta em RAG**. Para RAG,

instruction-following e aderência ao contexto fornecido pesam mais do que benchmarks de coding/matemática. Um modelo com índice mais baixo (ex: GLM-4.7-flash) pode performar melhor do que o índice sugere no caso específico de "ler contexto e responder com base nele" — e o inverso também é possível.

Recomendação: validar com eval próprio (perguntas + chunks reais da base de conhecimento) antes de fixar a escolha final por camada. Benchmark genérico é ponto de partida, não decisão final.

Tabela ampliada de preços (OpenRouter, referência de mercado)

Modelo	Input \$/M	Output \$/M	Contexto
GLM-4.7-flash	\$0.07	\$0.40	200K
Qwen3.5-flash-02-23	\$0.10	\$0.40	1M
GPT-4.1-nano	\$0.10	\$0.40	1M
DeepSeek V3 (chat)	\$0.14	\$0.28	65.5K
DeepSeek V3.2-exp	\$0.20	\$0.40	163.8K
GLM-4.6	\$0.40	\$1.75	202.8K
GLM-4.7	\$0.40	\$1.50	202.8K
Gemini 2.5 Flash	\$0.30	\$2.50	1M
MiniMax M2.5	\$0.30	\$1.10	196.6K
Mistral Large 2512	\$0.50	\$1.50	262.1K
Claude Haiku 4.5	\$1.00	\$5.00	200K
Gemini 2.5 Pro	\$1.25	\$10.00	1M
GPT-5	\$1.25	\$10.00	272K
Claude Sonnet 4.6	\$3.00	\$15.00	1M

Modelo	Input \$/M	Output \$/M	Contexto
Gemini 3.1 Pro (preview)	\$2.00	\$12.00	1M
Claude Opus 4.6	\$5.00	\$25.00	1M
Claude Opus 4.8	\$5.00	\$25.00	1M

4. Alavancas de redução de custo

- 1. **Prompt caching** — corta o custo do input cacheado em até 90%.
Essencial em RAG porque o system prompt + instruções de formatação são fixos entre chamadas; só o chunk recuperado e a pergunta variam.
- 2. **Batch API** — 50% de desconto, mas **não se aplica ao chat síncrono** (exige até 24h de processamento). Útil apenas para tarefas assíncronas, como reindexação noturna da base.
- 3. **Routing por provedor** — no mesmo modelo, diferentes provedores (via OpenRouter) podem variar preço e throughput; vale deixar o router escolher o mais barato que atenda a um SLA mínimo de velocidade.

5. Benchmark de mercado: como concorrentes cobram

Player	Modelo de cobrança	Preço	Observação
Fin (Intercom)	Por resolução	\$0.99/outcome	Só cobra se resolver — não cobra conversa que falha
Zendesk AI	Por resolução	\$1.50/resolução	

Player	Modelo de cobrança	Preço	Observação
Intercom (Fin add-on)	Pacote	\$990 / 1.000 resoluções	= \$0.99/resolução
Decagon	Híbrido	~\$50K/ano + ~\$0.50/resolução	Enterprise, contrato anual
Crescendo.ai	Por resolução	\$1.25/resolução	
Mercado geral (resolução)	Faixa	\$1–\$6/resolução	
Microsoft Copilot Studio	Por mensagem/crédito	~\$0.008/mensagem	25.000 mensagens inclusas por \$200/mês
HubSpot	Por crédito de IA	\$0.01/crédito	
Chatbase	Crédito variável por modelo	GPT-5.2: 2 créditos/resposta; Claude Opus: 5 créditos/resposta	Pondera o custo real do modelo usado no preço cobrado — referência direta para o desenho de créditos por camada

Benchmark de custo médio de mercado: uma interação resolvida por IA custa em média **\$0.50**, contra **\$6.00** de uma interação por humano — essa é a referência de valor entregue ao cliente, não o seu custo de modelo.

6. Estrutura de créditos por camada (modelo recomendado)

Inspirado no desenho do Chatbase: em vez de 1 crédito = 1 mensagem fixo, o consumo de créditos escala com a camada de modelo usada.

Camada	Créditos por mensagem
 Barata	1 crédito
 Média	2 créditos
 Forte	5–6 créditos

Isso protege a margem quando o roteamento escala para a camada cara, sem exigir que o cliente entenda qual modelo foi usado internamente.

Cruzamento custo de modelo × preço sugerido por mensagem

Camada	Custo/mensagem (modelo, com cache)	Preço sugerido/mensagem	Margem
 Barata	\$0,0005 – \$0,0015	\$0,008 – \$0,01	~6–15x
 Média	\$0,002 – \$0,005	\$0,015 – \$0,02	~5–8x
 Forte	\$0,015 – \$0,03	\$0,05 – \$0,08	~3–4x

Estimativa no volume alvo (1M+ mensagens/mês, mix 85/12/3)

- Custo médio ponderado de modelo: ~\$0,0015/mensagem
- Preço médio ponderado de crédito (≈1,85 créditos médios × \$0,01/crédito): ~~**\$0,0185/mensagem**~~
- Margem bruta efetiva: ~12x sobre custo de modelo – antes de infraestrutura, retrieval/embeddings e suporte.

Mesmo assim, o preço final fica **muito abaixo** do que concorrentes cobram por resolução (\$0,50–\$1,50), o que pode ser usado como vantagem competitiva de preço ou como margem de sobra para investir em qualidade/suporte.

7. Modelo pré-pago + pay-as-you-go

Princípio de design

Pacotes pré-pagos com créditos inclusos, **mais PAYG automático no overage** — nunca um corte seco de serviço. Hard-cutoff sem PAYG é o pior cenário operacional: o chatbot do cliente simplesmente para de responder em produção quando os créditos acabam.

Padrão validado no mercado (Microsoft Copilot Studio / Azure): começar com pacotes, habilitar PAYG como rede de segurança, e migrar para plano de pré-compra customizado quando houver dados de uso suficientes para negociar volume.

Proposta de estrutura de planos

Plano	Créditos inclusos	Preço/mês	Preço efetivo/crédito
Starter	50.000	\$399	\$0,0080
Growth	250.000	\$1.799	\$0,0072
Scale	1.000.000	\$6.499	\$0,0065
Overage (PAYG, qualquer plano)	—	—	\$0,009 – \$0,010/crédito
Enterprise (customizado)	Negociado	Negociado	Contrato anual, similar ao modelo Decagon

Lógica de cada elemento

- **Preço por crédito cai conforme o pacote cresce** — volume discount padrão de SaaS, incentiva upgrade de plano.
- **PAYG sempre um pouco mais caro que o crédito do pacote** — empurra o cliente a comprar o próximo pacote em vez de viver no overage permanentemente, e protege a margem em picos de uso imprevisíveis.

- **Créditos não expiram no mês** (ou expiram em 60–90 dias) — evita a sensação de "perdi dinheiro", uma das maiores fontes de churn em modelos de crédito.
 - **Acima do Scale (1M+ créditos/mês), migrar para tier Enterprise customizado** — clientes desse porte tendem a negociar contrato anual com comprometimento de volume, como faz a Decagon no mercado.
-

8. Próximos passos recomendados

1. **Rodar eval próprio** comparando 3–4 modelos candidatos por camada (ex: DeepSeek V3.2, GLM-4.7-flash, Claude Haiku 4.5, Claude Sonnet 4.6) contra perguntas e chunks reais da base de conhecimento — não confiar apenas em benchmark genérico para a decisão final.
 2. **Implementar prompt caching** desde o início — é a alavanca de maior impacto em custo para RAG, dado que o system prompt e as instruções de formatação se repetem em quase toda chamada.
 3. **Desenhar o critério de escalonamento entre camadas** com base nos 4 sinais listados na Seção 2 (score de retrieval, complexidade da pergunta, self-check de confiança, validação pós-resposta).
 4. **Validar a margem real** após incluir custos de infraestrutura, retrieval/embeddings e suporte — os ~12x de margem calculados na Seção 6 referem-se apenas ao custo de inferência do modelo.
 5. **Monitorar pricing da concorrência e dos modelos trimestralmente** — tanto os preços por token quanto o benchmark de mercado por resolução mudam com frequência neste momento do setor.
-

Documento gerado a partir de pesquisa com dados de jun/2026. Preços de modelos e de mercado mudam rapidamente — revalidar antes de fechar contratos ou definir pricing final.